

# Hash Table

A.Raspanti

April 1, 2021

## Contents

<b>1</b>	<b>Introduzione</b>	<b>2</b>
<b>2</b>	<b>Implementazione</b>	<b>2</b>
<b>3</b>	<b>Test Effettuati</b>	<b>3</b>
<b>4</b>	<b>Risultati</b>	<b>3</b>
4.1	Grafici . . . . .	3
4.2	Riflessioni . . . . .	4
<b>5</b>	<b>Riferimenti</b>	<b>4</b>

## 1 Introduzione

In questo esercizio si è effettuata la classificazione di immagini di numeri civici presi da immagini di Google Street View sfruttando l'implementazione del Perceptron fornita dalla libreria Python Scikit-learn.

Prendendo in esame il data set SVHN(Street View House Number), si è analizzato l'errore di predizione commesso sul test set e sul training set al crescere delle dimensioni con cui quest'ultimo è stato considerato in fase di addestramento. Il data set SVHN proviene da un difficile, irrisolto problema del mondo reale ovvero il riconoscimento di caratteri e numeri in immagini rappresentanti scene naturali. SVHN è ottenuto dalle immagini dei numeri civici prese da Google Street View. Esistono due formati del data set SVHN, quello preso in esame comprende immagini MNIST-like di dimensione 32x32 pixel centrate sul numero civico (alcune delle quali contengono dei "disturbi" alle parti). Il data set contiene 73257 immagini per l'addestramento training e 26032 per il testing. Le immagini sono state trasformate in grayscale per poterle dare in input al Perceptron.

Per precisare le immagini sono state ridimensionate a partire dal box che contiene il singolo carattere per farle diventare in formato 32x32; tuttavia questo processo introduce alcuni caratteri che distraggono ai lati del carattere al centro.

## 2 Implementazione

Il codice da me realizzato si articola in un unico file nel quale viene caricato il dataset e riformattato per essere compatibile con l'input del perceptron. houseNumberTest: All'interno di questa funzione vengono svolti i test che mirano ad evidenziare l'accuratezza raggiunta del Perceptron nella predizione del data set e del training set.

Al fine di effettuare le operazioni di test é risultato utile l'utilizzo di alcune liste ausiliarie:


- dimension: Questa lista contiene il numero di samples appartenenti al Training set utilizzatiti per l'apprendimento. Si é considerato dimensioni del Training set di  $2^k$  , per k crescente da 10 fino al massimo valore compatibile con il numero di samples messo a disposizione dal data set SVHN.
- testAccuracy: Questa lista, viene utilizzata per tenere traccia dell'accuratezza raggiunta nella predizione sul Test set al crescere del numero di samples utilizzati in fase di addestramento.
- trainAccuracy: Questa lista, viene utilizzata per tenere traccia dell'accuratezza raggiunta nella predizione sul Training set al crescere del numero di samples utilizzati in fase di addestramento.

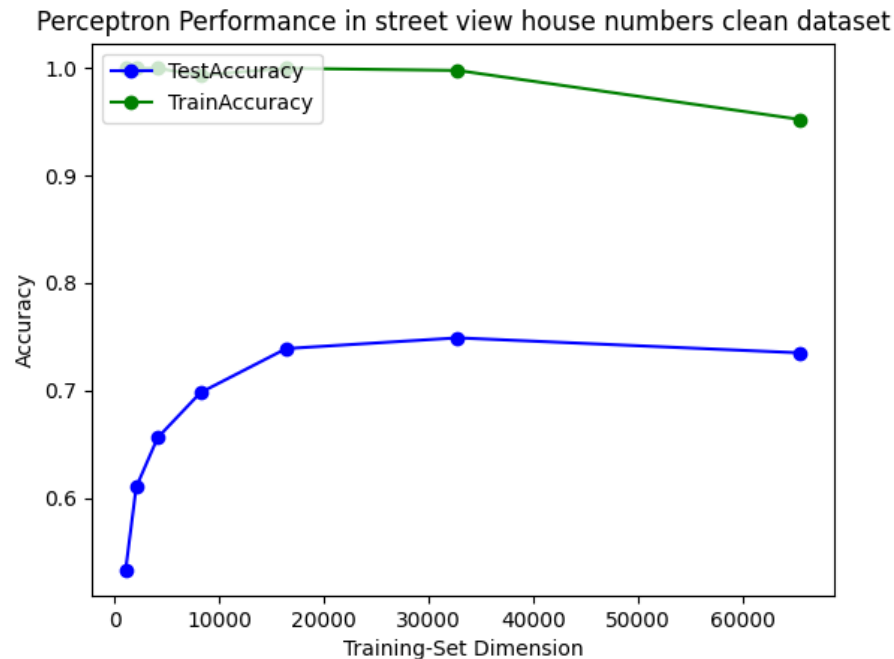
### 3 Test Effettuati

Per ciascuna cardinalità del training set vengono effettuate operazioni di addestramento del modello, il quale successivamente, è utilizzato per svolgere delle predizioni sul Test set e sul Training set. Il risultato delle predizioni è quindi usato per il calcolo delle accuratèzze raggiunte, le quali vengono poi salvate all'interno delle liste precedentemente descritte con l'intento di realizzare un grafico che dettagli le prestazioni ottenute al crescere del numero dei samples utilizzati. Sono stati effettuati ulteriori test poichè come vedremo dai grafici l'accuratèzza che riusciamo a raggiungere è molto bassa; questo è dato dal fatto che le immagini essendo ritagliate da un'immagine reale, introducono ai lati del carattere dei disturbi, questo inficia l'apprendimento da parte del perceptron il quale non impara in modo efficiente. Gli ulteriori test sono stati effettuati con un ripulimento del dataset, ritagliando ulteriormente le immagini per ridurre al minimo il disturbo. Questo ha portato ad un incremento dell'accuratèzza a livelli sopra l'70%.

## 4 Risultati

### 4.1 Grafici





## 4.2 Riflessioni

Il primo grafico mostra l'accuratezza utilizzando il dataset originale.

Il secondo grafico mostra l'accuratezza con il dataset "ripulito".

Vengono allegati con lo scopo di evidenziare come questo modello, al crescere della cardinalità dell'insieme di dati utilizzato in fase di addestramento, possa ottenere una maggiore accuratezza nella predizione. Come è possibile osservare i test effettuati hanno portato alla realizzazione di curve di apprendimento caratterizzate da un andamento logaritmico. Inoltre, come era ragionevole pensare, nei test che hanno preso in esame il Training set è stata raggiunta un'accuratezza maggiore rispetto a quella ottenuta negli esperimenti effettuati sul Test set. Come già anticipato nel paragrafo sui risultati vediamo come nel primo grafico con il dataset originale l'andamento è altalenante all'inizio per poi proseguire logaritmicamente; questo va a confermare il fatto che il dataset confonde il perceptron che non riesce ad imparare in modo efficace e questo si rispecchia in un'accuratezza molto bassa.

## 5 Riferimenti

- <https://scikit-learn.org/stable/>
- <http://ufldl.stanford.edu/housenumbers>